

수도권 인플루엔자 모델 Calibration

모수 식별성 — 진단·해결·결과

조현우

데이터: 국민건강보험공단 J09-J11 진료에피소드 (2018-2024)

2026년 6월

1. 연구 맥락

정책 목표: 정상 시기 인플루엔자 sick-leave / 학교 결석 정책의 ICER


모델:

- SVEIR ($S \rightarrow V \rightarrow E \rightarrow I \rightarrow R$) + 4-channel FOI (가정 / 직장 / 학교 / 기타)
- 연령 NIMS 15군 (5세 단위)
- 수도권 (서울 + 인천 + 경기), 4 정상 시즌

데이터: HIRA J09-J11 진료에피소드, 6 연령군

HIRA 의 장점:

- 카운트 단위 (인구 분모 깨끗)
- γ_{report} 해석이 명확 ("감염자 중 청구 비율")



2. γ_{report} 다시 — 탐지율의 의미

정의: 실제 감염자 중 HIRA 진료 청구로 잡힌 비율

$$\gamma_{\text{report}} = \frac{\text{정구 카운트}}{\text{실제 감염자}}$$

빙산 비유:

- 보이는 부분 = HIRA 청구 (분자, 측정 가능)
- 숨은 부분 = 무증상 + 자가관리 + 미진료 (분모, 측정 불가)

$\gamma = \text{level} \times \text{연령 상대비}$:

- **level**: Jung et al. (2025) $q = 0.67$ (감염 → 증상) 에서 무증상·미청구 제외 → **0.6** (비식별 anchor, R0 흡수 차원)
- **연령 상대비**: 데이터가 식별 가능한 차원 (sweep 에서 CDC 비율 NLL 최저 확인)

연령군	CDC 상대비	γ (level 0.6 적용)
어린이	1.45	0.87
성인	0.65	0.39
노인	0.90	0.54

3. 식별성 문제 — 곱셈의 함정

모델 관측 신호:

$$\text{청구 카운트} \propto \beta \times \phi \times \gamma \times s(t)$$

두 시나리오, 같은 청구:

	시나리오 A	시나리오 B
실제 감염 ($\beta \cdot \phi$)	100	250
탐지율 (γ)	0.25	0.10
HIRA 청구	25	25

데이터만 보면 A 와 B 구분 불가 — 구조적 비식별

핵심: 데이터를 더 모아도 곱 만 결정될 뿐 개별 분해 불가.





모델 구조 자체의 성질.

4. 진단 — Multi-start 가 보여준 다봉성

검증: 8개 시작점 multi-start (warm / bio_prior / 극단 / 무작위 등)

지표	값	의미
NLL spread	0.57%	8개 fit 거의 동일 적합
ϕ 평균 CV	53%	같은 NLL 위에 여러 mode
γ_{elder} CV	63%	분해 자유도 큼
β 평균 CV	65%	channel split swap

Multi-start Verification (8/8) — MULTIMODAL CONFIRMED
NLL spread 0.568% vs phi/gamma/beta CV 32-63%



5. R(0) 연령 구조 누락

2019-2020 시즌 fit:

Test	결과	의미
65+ peak ratio (pred/obs)	1.43	노인 구조적 과대
65+ raw attack rate	7.5% (정상)	감염 수준 자체는 적절
다른 5 연령 fit	0.63 - 1.11	65+ 만 outlier

원인 추적:

- 1. R(0) (초기 면역) = **균일 30%** (전 연령 동일)
- 2. 그러나 노인 실제 면역 (이전 시즌 누적) >> 30%
- 3. → 노인 S 모집단 **과대**, I 과대생성
- 4. → 데이터 fit 위해 γ_{elder} 가 흡수 (0.25 → 0.05 corner)

모델 내부 단순화 문제 — 외부 데이터가 흡수 → 수정 가능

6. 해결 ① — R(0) 계단 형식

변경: 균일 30% → 연령 계단

연령군	R(0) 기존	R(0) 계단	근거
0-19	0.30	0.10	최근 시즌 노출 적음 + 백신 coverage 낮음
20-49	0.30	0.30	기준
50-64	0.30	0.45	누적 노출 + 백신
65+	0.30	0.65	백신 정책 + 누적 면역

근거: POLYMOD 이전 시즌 누적 + Vandegrift 2010 미국 추정

효과:

- 65+ peak ratio 1.43 → 0.99
- γ_{elder} CDC band 안: 2/8 → 7/8 시작점
- γ_{elder} CV: 63% → 25%

7. 해결 ② — 추정 대상 분리

곱 $\beta \cdot \varphi \cdot \gamma$ 중 어느 차원을 데이터로 결정할 수 있나?

파라미터	의미	데이터 정보량	결정 방법
γ_{report}	탐지율	없음 (분모 미관측)	외부 고정 (CDC + PSA)
φ_{age}	연령별 감수성	약함	prior 좁게 (Cauchemez $\pm 15\%$)
$\beta_{channel}$	채널별 전파율	강함 (peak 시점·높이)	데이터로 추정 (NUTS)

Reparam: $\beta \cdot \varphi$ 곱셈 ridge $\rightarrow$ primary axis 를 $\log R_0$ 로 회전

- $\log R_0$ (시즌별 4) + 채널 비율 (시즌별 4) + φ (14)
- β 는 (R_0 , 채널 비율, φ) 에서 NGM 역산으로 derive

8. 결과 ① R0 식별 (production NUTS, 채널 정상화)

Production NUTS (NB 관측모델 + 채널 정상화, 300 warmup + 300 sample × 4 chain, wall 64분)


시즌	R0 mean	95% CI
2017-18	1.79	[1.74, 1.83]
2018-19	1.95	[1.91, 1.98]
2019-20	1.90	[1.85, 1.95]
2022-23	1.74	[1.68, 1.84]

전체: R0 mean 1.84, range [1.68, 1.98] — 전형적 seasonal flu (1-2.5)

수렴: divergence 0/2400, r_hat 1.007, ess 908

4 chain 일치 + 완벽 수렴 — R0 가 데이터로 식별되는 primary axis

8b. 결과 ①' Posterior predictive — 연령별 fit (피드백 3)

Posterior predictive (NB obs, $\phi_{nb} \approx 1.45$) — overall 95% coverage 95%

8c. 결과 ①” 관측모델: Poisson → NB

문제: Poisson 가정 (분산=평균) 으로는 청구 데이터 변동 못 잡음

- 주별 변동·보고 지연·요일 효과 → 실측 분산 > 평균 (과분산)
- 결과: posterior 띠 좁음, coverage 12%, 거기에 수렴까지 악화 (r_hat 2.38)

해법: 관측을 Negative Binomial-2 로

$$\text{obs} \sim \text{NegBin}(\mu = \text{pred}, \text{Var} = \mu + \mu^2/k)$$

결과:

지표	Poisson	NB
95% coverage	12%	95%
r_hat max	2.38	1.02
ess_min	5	581
R0 mean	1.96	1.90 (거의 동일)
wall	6h 25min	41분

NB 분산 파라미터 `phi_nb = 1.44 [1.30, 1.59]` — 식별 (r_hat 1.02)

8d. 결과 ① 4 채널 전파 분해 — 비식별 진단 후 정상화

시즌별 채널 mix (NB + work:other 비율 고정):

시즌	home	work	school	other
2017-18	0.36	0.12	0.31	0.22
2018-19	0.23	0.11	0.45	0.21
2019-20	0.23	0.11	0.44	0.21
2022-23	0.27	0.15	0.30	0.28

진단·해소된 3 종 비식별:

증상	원인	외부 근거 해소
home $\approx$ 0	γ_{adult} 절대값 너무 높음 $\rightarrow$ home β 가 성인 보정	γ level = 0.6 (Jung $q=0.67$ – 무증상/미청구) $\times$ CDC 연령 상대비
work $\approx$ 0	work/other 둘 다 성인 타겟 + HIRA 6 연령군 $\rightarrow$ 분해 정보 부족	work:other = 0.349 : 0.651 (NIMS 접촉 row-sum) 고정
school 0.62 과대	work 흡수 (둘 다 $R_0 \uparrow$ 효율 비슷)	위 두 해소로 자동 교정 (0.62 $\rightarrow$ 0.30-0.45)

데이터가 보는 것(home/school/덩어리 크기) 추정 + 못 보는 것(분배·level) 외부 근거 $\rightarrow$ single-channel dominance 없음, 역학적으로 타당

같은 sample 의 ϕ posterior:

chain	$\phi[0]$ (0-4세)	해석
-------	------------------	----

10. 비식별 ridge $\rightarrow$ field knowledge로 결정

(현재) 데이터만으로는 $\gamma \cdot \phi$ 를 정할 수 없다 (ridge)

- γ (탐지율): CDC reporting multiplier
- ϕ (연령 감수성): Cauchemez 등 문헌 범위 ($\pm 15\%$)
- β (전파력): 데이터로 추정 (R0)

11. 선행연구 대비 — Jung et al. (2025)

같은 데이터·모델 출발점, 다른 식별성 처리

측면	Jung et al. 2025	본 연구
데이터	HIRA 인플루엔자 청구	동일
모델	연령별 SEIR	동일
백신	한국 청소년·노인 정책	동일
식별성	reporting $q = 0.67$ 단일값 우회	진단·분해·고정 + PSA
정책 시뮬	백신 coverage 시나리오	sick-leave 정책 (수도권 metapop)
불확실성 정량	부분	$\beta \cdot R_0$ posterior + $\gamma \cdot \varphi$ PSA

방법론적 기여: identifiability 정면 진단·해결 + 출처 객체화 (γ_{registry})

12. 현재 진행 + 향후

현재 도달점 (완료):

- ✓
 - $\beta \cdot R_0$ 추정 완료 (NB + 채널 정상화 production, divergence 0, r_{hat} 1.007)
- ✓
 - $\gamma = \text{level}(0.6) \times \text{CDC 상대비}$ — Jung 2025 정합 + 데이터 식별 (객체화)
- ✓
 - $\phi = 1.0$ 고정 (3중 비식별 확정 후, 점고정)
- ✓
 - 4 채널 mix 정상화 (home 0.27 / work 0.12 / school 0.40 / other 0.22)
- ✓
 - Posterior predictive 95.2% coverage

식별성 정리 — 데이터가 보는 것 / 못 보는 것:

차원	정체	처리
R_0 (β 스케일)	데이터 식별 (peak·진폭)	NUTS 추정 ✓
home / school / (work+other) 덩어리	연령 곡선이 식별	NUTS 추정 ✓
γ level (전역 곱셈)	비식별 (R_0 흡수)	0.6 anchor (Jung)

13. 요약

- 비식별을 차원별로 진단·해소: 데이터가 보는 것은 추정, 못 보는 것은 외부 근거
- $R(0)$ 계단 $\rightarrow$ 노인 과대 + γ 흡수 해결 ($1.43 \rightarrow 0.99$)
- $\gamma = 0.6 \times \text{CDC 상대비}$ (Jung $q=0.67$ 정합), $\phi = 1.0$ 점고정
- work : other = 0.349 : 0.651 (NIMS 접촉비) — 4 채널 mix 정상화
- Production NB: R_0 1.84 [1.68, 1.98], r_{hat} 1.007, coverage 95.2%