

수도권 인플루엔자 모델 Calibration

모수 식별성 — 진단·해결·결과

조현우

데이터: 국민건강보험공단 J09-J11 진료에피소드 (2018-2024)

2026년 6월

1. 연구 맥락

정책 목표: 정상 시기 인플루엔자 sick-leave / 학교 결석 정책의 ICER


모델:

- SVEIR ($S \rightarrow V \rightarrow E \rightarrow I \rightarrow R$) + 4-channel FOI (가정 / 직장 / 학교 / 기타)
- 연령 NIMS 15군 (5세 단위)
- 수도권 (서울 + 인천 + 경기), 4 정상 시즌

데이터: HIRA J09-J11 진료에피소드, 6 연령군

HIRA 의 장점:

- 카운트 단위 (인구 분모 깨끗)
- γ_{report} 해석이 명확 ("감염자 중 청구 비율")



2. γ_{report} 다시 — 탐지율의 의미

정의: 실제 감염자 중 HIRA 진료 청구로 잡힌 비율

$$\gamma_{\text{report}} = \frac{\text{정구 카운트}}{\text{실제 감염자}}$$

빙산 비유:

- 보이는 부분 = HIRA 청구 (분자, 측정 가능)
- 숨은 부분 = 무증상 + 자가관리 + 미진료 (분모, 측정 불가)

노인 100명 감염, $\gamma=0.25$ 가정:

- 청구로 잡힘: 25명
- 못 잡힘: 75명 (만성질환 혼재 / 자가관리 / 응급실 미경유)

연령군	γ (CDC 2015)	의미
어린이	0.40	부모가 데려옴 → 잘 잡힘
성인	0.18	자가관리 ↑
노인	0.25	합병증 동반진단 + 백신 효과 분리

3. 식별성 문제 — 곱셈의 함정

모델 관측 신호:

$$\text{청구 카운트} \propto \beta \times \phi \times \gamma \times s(t)$$

두 시나리오, 같은 청구:

	시나리오 A	시나리오 B
실제 감염 ($\beta \cdot \phi$)	100	250
탐지율 (γ)	0.25	0.10
HIRA 청구	25	25

데이터만 보면 A 와 B 구분 불가 — 구조적 비식별

핵심: 데이터를 더 모아도 곱 만 결정될 뿐 개별 분해 불가.





모델 구조 자체의 성질.

4. 진단 — Multi-start 가 보여준 다봉성

검증: 8개 시작점 multi-start (warm / bio_prior / 극단 / 무작위 등)

지표	값	의미
NLL spread	0.57%	8개 fit 거의 동일 적합
ϕ 평균 CV	53%	같은 NLL 위에 여러 mode
γ_{elder} CV	63%	분해 자유도 큼
β 평균 CV	65%	channel split swap

Multi-start Verification (8/8) — MULTIMODAL CONFIRMED
NLL spread 0.568% vs phi/gamma/beta CV 32-63%



5. R(0) 연령 구조 누락

2019-2020 시즌 fit:

Test	결과	의미
65+ peak ratio (pred/obs)	1.43	노인 구조적 과대
65+ raw attack rate	7.5% (정상)	감염 수준 자체는 적절
다른 5 연령 fit	0.63 - 1.11	65+ 만 outlier

원인 추적:

- 1. R(0) (초기 면역) = **균일 30%** (전 연령 동일)
- 2. 그러나 노인 실제 면역 (이전 시즌 누적) >> 30%
- 3. → 노인 S 모집단 **과대**, I 과대생성
- 4. → 데이터 fit 위해 γ_{elder} 가 흡수 (0.25 → 0.05 corner)

모델 내부 단순화 문제 — 외부 데이터가 흡수 → 수정 가능

6. 해결 ① — R(0) 계단 형식

변경: 균일 30% → 연령 계단

연령군	R(0) 기존	R(0) 계단	근거
0-19	0.30	0.10	최근 시즌 노출 적음 + 백신 coverage 낮음
20-49	0.30	0.30	기준
50-64	0.30	0.45	누적 노출 + 백신
65+	0.30	0.65	백신 정책 + 누적 면역

근거: POLYMOD 이전 시즌 누적 + Vandegrift 2010 미국 추정

효과:

- 65+ peak ratio 1.43 → 0.99
- γ_{elder} CDC band 안: 2/8 → 7/8 시작점
- γ_{elder} CV: 63% → 25%

7. 해결 ② — 추정 대상 분리

곱 $\beta \cdot \phi \cdot \gamma$ 중 어느 차원을 데이터로 결정할 수 있나?

파라미터	의미	데이터 정보량	결정 방법
γ_{report}	탐지율	없음 (분모 미관측)	외부 고정 (CDC + PSA)
ϕ_{age}	연령별 감수성	약함	prior 좁게 (Cauchemez $\pm 15\%$)
$\beta_{channel}$	채널별 전파율	강함 (peak 시점·높이)	데이터로 추정 (NUTS)

Reparam: $\beta \cdot \phi$ 곱셈 ridge $\rightarrow$ primary axis 를 $\log R_0$ 로 회전

- $\log R_0$ (시즌별 4) + 채널 비율 (시즌별 4) + ϕ (14)
- β 는 (R_0 , 채널 비율, ϕ) 에서 NGM 역산으로 derive

8. 결과 ① R0 식별 (production NUTS, NB 관측모델)

Production NUTS (NB 관측모델, 200 warmup + 200 sample × 4 chain, wall 41분)

시즌	R0 mean	95% CI	폭
2017-18	1.83	[1.80, 1.87]	4%
2018-19	1.96	[1.94, 2.00]	3%
2019-20	1.94	[1.91, 1.97]	3%
2022-23	1.87	[1.83, 1.91]	4%

전체: R0 mean 1.90, range [1.78, 2.01] — 전형적 seasonal flu (1-2.5)


수렴: divergence 0/1600, r_hat 1.02, ess 581

4 시즌 모두: 95% CI 3-4% — 현실적 정책 신뢰구간

R0 가 primary axis 임을 4 chain 일치 + 깨끗한 수렴으로 확정

8b. 결과 ①' Posterior predictive — 연령별 fit (피드백 3)

Posterior predictive (NB obs, $\phi_{nb} \approx 1.45$) — overall 95% coverage 95%



8c. 결과 ①” 관측모델: Poisson → NB

문제: Poisson 가정 (분산=평균) 으로는 청구 데이터 변동 못 잡음

- 주별 변동·보고 지연·요일 효과 → 실측 분산 > 평균 (과분산)
- 결과: posterior 띠 좁음, coverage 12%, 거기에 수렴까지 악화 (r_hat 2.38)

해법: 관측을 Negative Binomial-2 로

$$\text{obs} \sim \text{NegBin}(\mu = \text{pred}, \text{Var} = \mu + \mu^2/k)$$

결과:

지표	Poisson	NB
95% coverage	12%	95%
r_hat max	2.38	1.02
ess_min	5	581
R0 mean	1.96	1.90 (거의 동일)
wall	6h 25min	41분

NB 분산 파라미터 `phi_nb = 1.44 [1.30, 1.59]` — 식별 (r_hat 1.02)

9. 결과 ② ϕ 비식별 실증

같은 sample 의 ϕ posterior:

chain	$\phi[0]$ (0-4세)	해석
0 (warm)	4.90	
1 (bio_prior)	5.73	chain 마다
2 (distributed)	6.37	서로 다른 mode
3 (home_dominant)	6.62	(ridge 위 다른 점)

진단	값	의미
ϕ posterior mean	3.17	prior median 1.0 무시
ϕ near tail (>2.0)	67%	prior 와 무관
r_hat (ϕ)	4.46	chain 분산
ess (ϕ)	5	거의 안 섞임

슬라이드 8 의 " ϕ 는 데이터 정보 약함" 진단을 데이터로 확정
→ ϕ 외부 고정치 정당 (prior 좁힘 or 점추정)

10. 비식별 ridge $\rightarrow$ field knowledge로 결정

(현재) 데이터만으로는 $\gamma \cdot \phi$ 를 정할 수 없다 (ridge)

- γ (탐지율): CDC reporting multiplier
- ϕ (연령 감수성): Cauchemez 등 문헌 범위 ($\pm 15\%$)
- β (전파력): 데이터로 추정 (RO)

11. 선행연구 대비 — Jung et al. (2025)

같은 데이터·모델 출발점, 다른 식별성 처리

측면	Jung et al. 2025	본 연구
데이터	HIRA 인플루엔자 청구	동일
모델	연령별 SEIR	동일
백신	한국 청소년·노인 정책	동일
식별성	reporting $q = 0.67$ 단일값 우회	진단·분해·고정 + PSA
정책 시뮬	백신 coverage 시나리오	sick-leave 정책 (수도권 metapop)
불확실성 정량	부분	$\beta \cdot R_0$ posterior + $\gamma \cdot \varphi$ PSA

방법론적 기여: identifiability 정면 진단·해결 + 출처 객체화 (γ_{registry})

12. 현재 진행 + 향후

현재 도달점 (완료):

- ✓
 - $\beta \cdot R_0$ 추정 완료 (production NUTS, 시즌별 95% CI 산출, divergence 0)
- ✓
 - γ 외부 고정 (CDC 2015 + `gamma_registry` 객체화 → 한국 데이터 교체 가능)
- ✓
 - $\phi = 1.0$ 고정 (3중 비식별 확정 후, 점고정)
- ✓
 - Posterior predictive 검증 — 연령별 peak 재현 (피드백 3)

다음 (Stage 4-5):

1. 수도권 metapop 확장 — 1,154 행정동
 - 회사 밀집 vs 주거 밀집 → sick-leave 정책 채널별 효과 (work / school 분리)
 - 출퇴근 mobility 영향
2. ICER + PSA
 - γ_{source} PSA, ϕ Cauchemez $\pm 15\%$, R_0 posterior CI → 정책 신뢰구간
 - 백신 vs sick-leave vs 학교결석 정책 비교

13. 요약

- 곱셈 결합 $\beta \cdot \phi \cdot \gamma \rightarrow R_0$ (β) 추정 / $\gamma \cdot \phi$ 외부 고정
- $R(0)$ 계단으로 노인 과대생성 + γ 흡수 해결 ($1.43 \rightarrow 0.99$)
- Production NB NUTS: R_0 시زن별 95% CI (mean 1.90, divergence 0, r_{hat} 1.02)
- Posterior predictive coverage 95.2% — 모델 구조가 데이터 재현
- 두 종류 비식별 모두 처리: 구조적 ($\gamma \cdot \phi$ 외부 고정) + practical (NB 가 자동 해소)