

수도권 인플루엔자 모델 Calibration

모수 식별성 — 진단·해결·결과

조현우

데이터: 국민건강보험공단 J09-J11 진료에피소드 (2018-2024)

2026년 6월

1. 연구 맥락

정책 목표: 정상 시기 인플루엔자 sick-leave / 학교 결석 정책의 ICER


모델:

- SVEIR ($S \rightarrow V \rightarrow E \rightarrow I \rightarrow R$) + 4-channel FOI (가정 / 직장 / 학교 / 기타)
- 연령 NIMS 15군 (5세 단위)
- 수도권 (서울 + 인천 + 경기), 4 정상 시즌

데이터: HIRA J09-J11 진료에피소드, 6 연령군

HIRA 의 장점:

- 카운트 단위 (인구 분모 깨끗)
- γ_{report} 해석이 명확 ("감염자 중 청구 비율")



2. γ_{report} 다시 — 탐지율의 의미

정의: 실제 감염자 중 HIRA 진료 청구로 잡힌 비율

$$\gamma_{\text{report}} = \frac{\text{정구 카운트}}{\text{실제 감염자}}$$

빙산 비유:

- 보이는 부분 = HIRA 청구 (분자, 측정 가능)
- 숨은 부분 = 무증상 + 자가관리 + 미진료 (분모, 측정 불가)

$\gamma = \text{level} \times \text{연령 상대비}$:

- **level**: Jung et al. (2025) $q = 0.67$ (감염 → 증상) 에서 무증상·미청구 제외 → **0.6** (비식별 anchor, R0 흡수 차원)
- **연령 상대비**: 데이터가 식별 가능한 차원 (sweep 에서 CDC 비율 NLL 최저 확인)

연령군	CDC 상대비	γ (level 0.6 적용)
어린이	1.45	0.87
성인	0.65	0.39
노인	0.90	0.54

3. 식별성 문제 — 곱셈의 함정

모델 관측 신호:

$$\text{청구 카운트} \propto \beta \times \phi \times \gamma \times s(t)$$

두 시나리오, 같은 청구:

	시나리오 A	시나리오 B
실제 감염 ($\beta \cdot \phi$)	100	250
탐지율 (γ)	0.25	0.10
HIRA 청구	25	25

데이터만 보면 A 와 B 구분 불가 — 구조적 비식별





핵심: 데이터를 더 모아도 곱 만 결정될 뿐 개별 분해 불가.
모델 구조 자체의 성질.

4. 진단 — Multi-start 가 보여준 다봉성

검증: 8개 시작점 multi-start (warm / bio_prior / 극단 / 무작위 등)

지표	값	의미
NLL spread	0.57%	8개 fit 거의 동일 적합
ϕ 평균 CV	53%	같은 NLL 위에 여러 mode
γ_{elder} CV	63%	분해 자유도 큼
β 평균 CV	65%	channel split swap

Multi-start Verification (8/8) — MULTIMODAL CONFIRMED
NLL spread 0.568% vs phi/gamma/beta CV 32-63%



5. R(0) 연령 구조 누락

2019-2020 시즌 fit:

Test	결과	의미
65+ peak ratio (pred/obs)	1.43	노인 구조적 과대
65+ raw attack rate	7.5% (정상)	감염 수준 자체는 적절
다른 5 연령 fit	0.63 - 1.11	65+ 만 outlier

원인 추적:

- 1. R(0) (초기 면역) = **균일 30%** (전 연령 동일)
- 2. 그러나 노인 실제 면역 (이전 시즌 누적) >> 30%
- 3. → 노인 S 모집단 **과대**, I 과대생성
- 4. → 데이터 fit 위해 γ_{elder} 가 흡수 (0.25 → 0.05 corner)

모델 내부 단순화 문제 — 외부 데이터가 흡수 → 수정 가능

6. 해결 ① — R(0) 계단 형식

변경: 균일 30% → 연령 계단

연령군	R(0) 기존	R(0) 계단	근거
0-19	0.30	0.10	최근 시즌 노출 적음 + 백신 coverage 낮음
20-49	0.30	0.30	기준
50-64	0.30	0.45	누적 노출 + 백신
65+	0.30	0.65	백신 정책 + 누적 면역

근거: POLYMOD 이전 시즌 누적 + Vandegrift 2010 미국 추정

효과:

- 65+ peak ratio 1.43 → 0.99
- γ_{elder} CDC band 안: 2/8 → 7/8 시작점
- γ_{elder} CV: 63% → 25%

7. 해결 ② — 추정 대상 분리

곱 $\beta \cdot \varphi \cdot \gamma$ 중 어느 차원을 데이터로 결정할 수 있나?

파라미터	의미	데이터 정보량	결정 방법
γ_{report}	탐지율	없음 (분모 미관측)	외부 고정 (CDC + PSA)
φ_{age}	연령별 감수성	약함	prior 좁게 (Cauchemez $\pm 15\%$)
$\beta_{channel}$	채널별 전파율	강함 (peak 시점·높이)	데이터로 추정 (NUTS)

Reparam: $\beta \cdot \varphi$ 곱셈 ridge $\rightarrow$ primary axis 를 $\log R_0$ 로 회전

- $\log R_0$ (시즌별 4) + 채널 비율 (시즌별 4) + φ (14)
- β 는 (R_0 , 채널 비율, φ) 에서 NGM 역산으로 derive

8. 결과 ① R0 식별 (production NUTS, 채널 정상화)

Production NUTS (NB 관측모델 + 채널 정상화, 300 warmup + 300 sample × 4 chain, wall 64분)

시즌	R0 mean	95% CI
2017-18	1.79	[1.74, 1.83]
2018-19	1.95	[1.91, 1.98]
2019-20	1.90	[1.85, 1.95]
2022-23	1.74	[1.68, 1.84]


전체: R0 mean 1.84, range [1.68, 1.98] — 전형적 seasonal flu (1-2.5)

수렴: divergence 0/2400, r_hat 1.007, ess 908

4 chain 일치 + 완벽 수렴 — R0 가 데이터로 식별되는 primary axis

8b. 결과 ①' Posterior predictive — 연령별 fit (피드백 3)

Posterior predictive (NB obs, $\phi_{nb} \approx 1.45$) — overall 95% coverage 95%



8c. 결과 ①” 관측모델: Poisson → NB

문제: Poisson 가정 (분산=평균) 으로는 청구 데이터 변동 못 잡음

- 주별 변동·보고 지연·요일 효과 → 실측 분산 > 평균 (과분산)
- 결과: posterior 띠 좁음, coverage 12%, 거기에 수렴까지 악화 (r_hat 2.38)

해법: 관측을 Negative Binomial-2 로

$$\text{obs} \sim \text{NegBin}(\mu = \text{pred}, \text{Var} = \mu + \mu^2/k)$$

결과:

지표	Poisson	NB
95% coverage	12%	95%
r_hat max	2.38	1.02
ess_min	5	581
R0 mean	1.96	1.90 (거의 동일)
wall	6h 25min	41분

NB 분산 파라미터 `phi_nb = 1.44 [1.30, 1.59]` — 식별 (r_hat 1.02)

8d. 결과 ① 4 채널 전파 분해 — 비식별 진단 후 정상화

시즌별 채널 mix (NB + work:other 비율 고정):

시즌	home	work	school	other
2017-18	0.36	0.12	0.31	0.22
2018-19	0.23	0.11	0.45	0.21
2019-20	0.23	0.11	0.44	0.21
2022-23	0.27	0.15	0.30	0.28

진단·해소된 3 종 비식별:

증상	원인	외부 근거 해소
home $\approx$ 0	γ_{adult} 절대값 너무 높음 $\rightarrow$ home β 가 성인 보정	γ level = 0.6 (Jung $q=0.67$ – 무증상/미청구) $\times$ CDC 연령 상대비
work $\approx$ 0	work/other 둘 다 성인 타겟 + HIRA 6 연령군 $\rightarrow$ 분해 정보 부족	work:other = 0.349 : 0.651 (NIMS 접촉 row-sum) 고정
school 0.62 과대	work 흡수 (둘 다 $R_0 \uparrow$ 효율 비슷)	위 두 해소로 자동 교정 (0.62 $\rightarrow$ 0.30-0.45)

데이터가 보는 것(home/school/덩어리 크기) 추정 + 못 보는 것(분배·level) 외부 근거 $\rightarrow$ single-channel dominance 없음, 역학적으로 타당

9. 결과 ② ϕ 비식별 실증

같은 sample 의 ϕ posterior:

chain	$\phi[0]$ (0-4세)	해석
0 (warm)	4.90	
1 (bio_prior)	5.73	chain 마다
2 (distributed)	6.37	서로 다른 mode
3 (home_dominant)	6.62	(ridge 위 다른 점)

진단	값	의미
ϕ posterior mean	3.17	prior median 1.0 무시
ϕ near tail (>2.0)	67%	prior 와 무관
r_hat (ϕ)	4.46	chain 분산
ess (ϕ)	5	거의 안 섞임

슬라이드 8 의 " ϕ 는 데이터 정보 약함" 진단을 데이터로 확정
→ ϕ 외부 고정값이 정당 (prior 좁힘 or 점추정)

10. 비식별 ridge $\rightarrow$ field knowledge로 결정

(현재) 데이터만으로는 $\gamma \cdot \phi$ 를 정할 수 없다 (ridge)

- γ (탐지율): CDC reporting multiplier
- ϕ (연령 감수성): Cauchemez 등 문헌 범위 ($\pm 15\%$)
- β (전파력): 데이터로 추정 (R0)

11. 선행연구 대비 — Jung et al. (2025)

같은 데이터·모델 출발점, 다른 식별성 처리

측면	Jung et al. 2025	본 연구
데이터	HIRA 인플루엔자 청구	동일
모델	연령별 SEIR	동일
백신	한국 청소년·노인 정책	동일
식별성	reporting $q = 0.67$ 단일값 우회	진단·분해·고정 + PSA
정책 시뮬	백신 coverage 시나리오	sick-leave 정책 (수도권 metapop)
불확실성 정량	부분	$\beta \cdot R_0$ posterior + $\gamma \cdot \varphi$ PSA

방법론적 기여: identifiability 정면 진단·해결 + 출처 객체화 (γ_{registry})

12a. 채널 식별성 한계 — 4시즌·방학 모두 실패

데이터로 식별



: R0, school 채널, other 채널, 계절성, winter break

데이터로 식별 불가



: home, work 채널

시도	결과
단일 시즌 4-channel free	home, work ≈ 0
Winter break 모델 (school_only)	home, work ≈ 0
Winter break + 접촉 재배분 (κ 재사용)	home, work ≤ 0.01
amp $\times$ realloc sweep (9 조합)	home ≤ 0.004
4 시즌 합동 + 방학 + amp	home ≤ 0.011 , work ≤ 0.011

원인 (구조적): HIRA 6 연령군 집계에서 30-44 (home/work) 신호가 18-44 bucket에 묻힘. ILI 동일 — 더 고운 데이터 없음.

→ home, work 는 field knowledge prior 로 채움 (φ , γ 와 같은 논리)

12b. 진단 여정의 정직 — 이전 결론 재평가

방학 발견 (NLL +400K) 이 이전 진단들의 전제를 흔들. 정직히 재평가:

이전 결론	재평가 (방학 ON 진단 후)
γ level=0.6 으로 home 살림 (0.27)	방학 누락 보정 효과였음 — γ CDC 로 충분
work : other = 0.349 NIMS 고정	그 시점 일부 정합화 — 지금은 4 조합 prior 일반화
channel mix 4 채널 정상화 표	방학 누락 환경의 채널 분리 산물

진짜 발견 (재평가 후에도 robust):

- ✓ winter break (NLL +400K) — 새 메커니즘
- ✓ amp 식별 (0.9 선호) — 데이터가 강한 계절성 + 방학 동시 원함
- ✓ RO 식별 (시즌별 ~2.0)
- ✓ home/work 구조적 한계 확정 — 4-시즌·방학·재배분 다 실패

교훈: misspecification (방학 누락) 이 "가짜 비식별" 처럼 보이게 함 — 진단·해소를 반복하며 자기수정

12c. 채널 비율 — field knowledge prior (4 조합)

두 근거 (R0 기여 기준):



	home	work	school	other	비고
A (NIMS contact)	0.27	0.20	0.17	0.37	unit R0 보정
B (Italy 2009 H1N1 문헌)	0.40	0.10	0.27	0.23	work 3-15% 불확실

4 조합 × 2 강도 fit (4 시즌 평균):

combo	home	work	school	other	R0	total obj
A_strong	0.11	0.13	0.27	0.49	1.98	-28.31M
A_weak	0.14	0.15	0.28	0.43	1.98	-28.35M
B_strong	0.15	0.10	0.28	0.47	1.98	-28.32M
B_weak	0.13	0.06	0.29	0.53	1.99	-28.36M

prior 추가 NLL 손실 ~85K (multi-start 잡음 수준) — 데이터 강하게 거부 안 함.

12d. 정책 효과 robust성 — 핵심 메시지



정책	averted 범위 (4 combos)	판정
학교 폐쇄 (p_school=0.5)	98.3% ~ 98.6% (span 0.3%)	✅ 강건 (어떤 가정이든)
병가 (p_work=0.4)	-2.8% ~ +2.2% (span 5.0%)	⚠️ 효과 작음 (robust) / 부호 가정 의존

학교 정책 → 강한 결론 / 병가 정책 → 한국 직장전파 외부 데이터 필요

13. 현재 진행 + 향후

Calibration 완료 (재평가 후):

- ✓
 - RO 시즌별 식별 (~2.0)
- ✓
 - school + other 채널 식별
- ✓
 - winter break 모델 (NLL +400K) + amp 식별 (~0.9)
- ✓
 - home/work 구조적 한계 확정 → 4 조합 field knowledge prior

정책 효과 (4 조합 robust 분석):

- ✓
 - 학교 폐쇄 98.3-98.6% (강건)
- ⚠
 - 병가 -2.8 ~ +2.2% (효과 작음 robust, 부호 가정 의존)

다음 (구조·외부 데이터):

- TODO: 한국 직장 전파 비중 (KOSIS / surveillance) — 병가 부호 확정
- TODO: HIRA 외래/입원 / KDCA serosurvey 활용 (현재 calibration 외부 보강)

14. 요약

- 비식별·misspec 반복 진단 → 데이터가 보는 것 추정, 못 보는 것 외부 근거
- R(0) 계단 + winter break (NLL +400K) — 진짜 모델 개선
- 데이터 식별: R0, school, other, 계절성 (amp~0.9), 방학 효과
- 데이터 한계 (구조): home, work — field knowledge prior 4 조합 robust 분석
- 정책 결론: 학교폐쇄 98% 강건 / 병가 $\pm$, 외부 데이터 필요